

US09 — Développer et évaluer le modèle

Simulation du rendement agricole au Sénégal · Random Forest et service de simulation

Random Forest
modèle retenu

0,575 t/ha
MAE sur test

−9 %
MAE vs baseline

81 %
réponse cohérente à la pluie

Synthèse. Le modèle retenu est une **forêt aléatoire** (Random Forest) qui estime le rendement d'une campagne à partir de 8 paramètres qu'un utilisateur peut fournir. Sur les années de test (2011–2015), il fait mieux que la référence « rendement moyen de la région pour cette culture » : MAE 0,575 contre 0,634 t/ha, RMSE 1,312 contre 1,477. Il réagit à la pluie de façon plausible : du mil à Kaolack passe de 0,44 t/ha avec 250 mm à 0,71 t/ha avec 500 mm. Il est exposé par l'API (POST /api/v1/predictions/simulation) pour le dashboard.

1. Récupération du dataset et vérification

Le dataset préparé en US08 est lu depuis le dernier export (ml_rendement_campagne_20261007.parquet) : 7 697 campagnes, 8 variables, train 6 456 / test 1 241. Les tests unitaires vérifient avant tout entraînement que la pluie est connue partout, que les catégories sont valides et que ni la production ni la cible ne figurent parmi les entrées.

2. Analyse des variables

L'importance de chaque variable est mesurée sur le test : on brouille une variable et on regarde de combien l'erreur augmente.




Figure 1 — Importance des variables (hausse de la MAE en t/ha quand la variable est brouillée).

- **La culture domine** (+1,06 t/ha) : le manioc rend dix fois plus que le mil.
- **La région, la température, la superficie et la pluie** viennent ensuite (+0,052 à +0,010 t/ha). En moyenne sur toutes les campagnes, la pluie pèse peu, car la plupart des années sont proches de la normale. Elle devient décisive dans les années sèches, précisément celles qu'on veut simuler.
- **L'année et la saison** n'apportent presque rien sur la période de test.

3. Configuration d'entraînement

Paramètre	Choix
Données	train 1960–2010, test 2011–2015 (découpage dbt, temporel)
Préparation	One-hot des 4 catégories ; médiane pour la température manquante (apprise sur train)
Modèle	Random Forest, 200 arbres, graine fixe (résultats reproductibles)
Réglage	Taille minimale des feuilles testée sur 2006–2010 (apprentissage 1960–2005)
Métriques (US07)	MAE, RMSE, R ² sur test ; détail par culture et par origine du climat
Critère	Battre la baseline en MAE et en RMSE ; réagir de façon cohérente à la pluie

4. Modèles comparés

Tous les modèles reçoivent les mêmes 8 variables (sans le rendement de l'année précédente, inconnu pour une campagne future) :

Modèle	MAE test	RMSE test	R ² test	Conclusion
Baseline : moyenne région × culture	0,634	1,477	0,609	Référence
Régression Ridge	0,647	1,371	0,662	Ne bat pas la baseline en MAE
Ridge, cible en logarithme	0,644	1,448	0,624	Ne bat pas la baseline en MAE
Gradient boosting	0,624	1,399	0,649	Proche, sans plus
Random Forest	0,575	1,312	0,691	Retenu

Les modèles linéaires supposent qu'un millimètre de pluie a toujours le même effet, quelle que soit la culture. Les données montrent le contraire : l'effet est fort en année sèche et s'atténue ensuite. La forêt aléatoire apprend ces seuils sans qu'on ait à les décrire.

5. Entraînement du premier modèle

Une première forêt avec des feuilles d'une seule campagne avait la meilleure erreur de validation (0,643). Elle réagissait pourtant mal à la pluie : pour l'arachide à Fatick, elle prédisait 1,98 t/ha avec 200 mm et 0,89 avec 500 mm. Avec des feuilles aussi petites, chaque arbre retient des cas particuliers, au lieu de la tendance générale.

6. Ajustement du modèle

Feuille minimale (campagnes)	MAE validation 2006–2010
1	0,643
5	0,748
10	0,718
20	0,656
50	1,142

Règle retenue : **la plus grande feuille dont l'erreur reste à moins de 5 % de la meilleure**, soit **20 campagnes** (0,656 contre 0,643). C'est le modèle le plus simple parmi les meilleurs. La réponse à la pluie devient cohérente dans 81 % des cas (contre 39 % avec des feuilles d'une campagne), et l'erreur sur test baisse aussi. Le choix ne regarde jamais le test.

7. Évaluation sur le test (métriques US07)

Modèle	MAE (t/ha)	RMSE	R ²
Baseline région × culture	0,634	1,477	0,609
Random Forest	0,575	1,312	0,691

Origine du climat	Campagnes	MAE modèle	MAE baseline
mesuré dans la région	884	0,641	0,700
région voisine	357	0,411	0,469

Le modèle fait aussi bien sur les régions qui empruntent le climat de leur voisine : la règle de la région voisine ne dégrade pas les prédictions.

8. Comparaison des performances




Figure 2 — Erreur moyenne sur test, par culture.

Culture	Campagnes	MAE modèle	MAE baseline	Gain
Arachide (en coque)	189	0,210	0,215	oui
Fonio	28	0,093	0,141	oui
Manioc	122	2,310	2,980	oui
Maïs	178	0,498	0,413	non
Mil	173	0,164	0,157	non
Niébé	176	0,130	0,142	oui
Patate douce	5	8,960	8,608	non
Riz	136	1,131	1,142	oui
Sorgho	180	0,241	0,249	oui
Sésame	54	0,144	0,176	oui

Le gain est net pour le manioc, le fonio et le sésame, et léger pour l'arachide, le niébé, le riz et le sorgho. Pour le maïs, le mil et la patate douce, le modèle ne fait pas mieux que la moyenne historique : la simulation reste utilisable, mais l'utilisateur doit le savoir (la réponse de l'API indique l'erreur moyenne de chaque culture).

9. Analyse des erreurs

- **Erreur médiane : 0,22 t/ha.** La moitié des campagnes sont prédites à moins de 0,22 t/ha près.
- **Les erreurs sont concentrées :** 1 % des campagnes produit 15 % de l'erreur totale.

- **La patate douce** à Ziguinchor (réel 8 à 12 t/ha, prédit 0,65) : cette culture n'a presque pas de données, et le modèle ne la connaît pas assez.
- **Le manioc** : rendements très variables (jusqu'à 25 t/ha à Kaolack en 2015, probablement une erreur de saisie à vérifier).

Année	Région	Culture	Réel	Prédit
2015	Kaolack	Manioc	25,00	5,68
2013	Ziguinchor	Patate douce	12,00	0,65
2013	Ziguinchor	Patate douce	10,56	0,65
2014	Ziguinchor	Patate douce	9,75	0,65
2015	Louga	Manioc	15,00	5,92
2013	Ziguinchor	Patate douce	8,53	0,65

10. Vérification sur le jeu de test




Figure 3 — Rendement réel et prédit sur 2011-2015 (échelles logarithmiques).

Les points suivent la diagonale. L'erreur reste stable d'une année à l'autre (de 0,505 à 0,631 t/ha) : le modèle ne se dégrade pas en s'éloignant de la période d'entraînement.

11. Sélection du modèle

La forêt aléatoire est retenue : elle bat la baseline en MAE et en RMSE sur le test, et elle est la seule à réagir à la pluie de façon plausible, ce qui est indispensable pour un outil de simulation.

12. Validation définitive

- **Réentraînement sur toutes les années** (1960-2015), avec le même réglage, pour le modèle de production.
- **Contrôles des saisies** : culture, région, saison et système inconnus refusés, avec la liste des valeurs possibles ; superficie strictement positive ; rendement jamais négatif.
- **26 tests automatiques** (modèle et API) : absence de fuite du test, priorité du climat, plus de pluie → rendement plus élevé, saisies invalides refusées.

13. Utilisation par le service de simulation

Le climat utilisé est choisi dans cet ordre :

Priorité	Source	Quand
1	Pluie et température saisies	L'utilisateur teste un scénario (« et si la pluie était de 300 mm ? »)
2	Climat observé (GalsenAPI → Snowflake)	La campagne est passée et tous ses mois sont mesurés
3	Normale de la région	Campagne future ou non mesurée (« année normale »)

Le climat observé vient de GalsenAPI, la source qui a servi à l'entraînement. Il est calculé de la même façon (moyenne des stations de la région, cumul sur les mois de la saison), donc sans écart entre l'apprentissage et l'usage.

```
POST /api/v1/predictions/simulation
{"produit": "Mil", "region": "Kaolack", "superficie_ha": 1000, "annee": 2027}
```

Scénario (mil, Kaolack, 1 000 ha, 2027)	Pluie	Rendement	Production
Année normale	498 mm	0,71 t/ha	715 t
Année sèche (saisie)	250 mm	0,44 t/ha	436 t




Figure 4 — Rendement simulé selon la pluie saisie, à Kaolack.

La réponse contient aussi des **repères** : le rendement moyen historique de la culture dans la région, l'erreur moyenne du modèle pour cette culture, et l'origine du climat utilisé.

14. Fiche du modèle

Rubrique	Description
Nom	Random Forest de simulation du rendement (version 20261007_162315)
Entrées	culture, région, saison, système, superficie, année, pluie, température
Sortie	rendement (t/ha) et production (t)
Réglages	200 arbres, feuilles d'au moins 20 campagnes
Performances test	MAE 0,575 t/ha · RMSE 1,312 · R ² 0,691
Usage prévu	Comparer des scénarios (sec, normal, humide) et estimer une production attendue
Limites	Pas plus précis que la moyenne historique pour le maïs, le mil et la patate douce ; années futures traitées comme 2015 ; contre-saison seulement à Saint-Louis ; climat observé limité à la dernière synchronisation